

## 3.线性方程组的直接解法

线性方程组的解法分为直接解法与迭代解法。

### 3.1基本概念

- **向量的范数**：记为 $\|\cdot\|$

向量的范数具有**正定性**、**正齐次性**、**三角不等式**。

对于数域 $\mathbb{K}$ 上的线性空间 $S$ ，若定义了范数，则称为**赋范线性空间**。

**$p$ -范数**： $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ ， $\|\mathbf{x}\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$ ， $p > 1$ 。

**内积范数**：针对内积 $\langle x, y \rangle$ ，定义范数 $\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$ 。

三种常用范数：

1. **1-范数**： $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$ ，也被称为**曼哈顿范数**

2. **2-范数**： $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$ ，也被称为**欧式范数/内积范数**

3.  **$\infty$ -范数**： $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$ ，也被称为**“最大”范数**

*Theorem 3.6*：存在 $f \in C^1$ ，使得 $\|\mathbf{x}\| = f(x_1, x_2, \dots, x_n)$ 。

*Theorem 3.7 (不同范数的等价性)*： $c_1 \|\mathbf{x}\|_s \leq \|\mathbf{x}\|_t \leq c_2 \|\mathbf{x}\|_s$ ，其中 $c_1, c_2 > 0$ 为与 $\mathbf{x}$ 无关的常数。

根据*Theorem 3.7*，在某种范数下成立的一些结论在其他范数下也成立。

*Theorem 3.8*： $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^* \Leftrightarrow \lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\|$

根据*Theorem 3.7*，为证明*Theorem 3.8*，只需说明其对于 $\infty$ -范数成立即可。而这是显然的。

- **矩阵的范数**

对 $\mathbb{R}^{n \times n}$ 空间的**矩阵范数**，需要增加一些条件：

1. 增加对矩阵乘法的要求： $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$

2. **相容性条件**： $\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$

根据某种向量范数 $\|\mathbf{x}\|_v$ ，定义矩阵的**算子范数**（也称为**向量诱导范数**）：

$$\|\mathbf{A}\|_v = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_v}{\|\mathbf{x}\|_v}, \quad \mathbf{x} \in \mathbb{R}^n, \mathbf{A} \in \mathbb{R}^{n \times n}$$

直观理解，也即 $\mathbf{Ax}$ 对向量 $\mathbf{x}$ 的最大拉伸倍数（也可能 $< 1$ ）。对于 $\|\mathbf{x}\|_v = 1$ ， $\mathbf{x}$ 的端点轨迹为二维空间中的单位圆，而 $\mathbf{Ax}$ 向量端点的轨迹为椭圆， $\|\mathbf{A}\|_v$ 就是这个椭圆**半长轴**的长度。矩阵范数的相容性条件显然成立，对矩阵乘法要求的证明如下：

$$\begin{aligned} \|\mathbf{AB}\|_v &= \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{ABx}\|_v}{\|\mathbf{x}\|_v} = \max_{\mathbf{x} \neq \mathbf{0}} \left( \frac{\|\mathbf{ABx}\|_v}{\|\mathbf{Bx}\|_v} \cdot \frac{\|\mathbf{Bx}\|_v}{\|\mathbf{x}\|_v} \right) \\ &\leq \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A(Bx)}\|_v}{\|\mathbf{Bx}\|_v} \cdot \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Bx}\|_v}{\|\mathbf{x}\|_v} \\ &\leq \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_v}{\|\mathbf{x}\|_v} \cdot \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Bx}\|_v}{\|\mathbf{x}\|_v} \\ &= \|\mathbf{A}\|_v \cdot \|\mathbf{B}\|_v \end{aligned}$$

常用的矩阵范数：

1. **1-范数**： $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ （竖列元素绝对值之和的最大值）

2.  $\infty$ -范数:  $\|\mathbf{A}\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$
3. 2-范数:  $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}$ , 其中,  $\lambda_{\max}$  表示取矩阵的最大特征值。
4. Frobenius范数:  $\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2} = \sqrt{\text{tr}(\mathbf{A}^T \mathbf{A})}$

## 3.2问题的敏感性

$$\mathbf{Ax} = \mathbf{b} \implies \mathbf{A}(\mathbf{x} + \Delta \mathbf{x}) = \mathbf{b} + \Delta \mathbf{b}$$

$$\text{条件数} \text{cond} = \frac{\|\Delta \mathbf{x}\| / \|\mathbf{x}\|}{\|\Delta \mathbf{b}\| / \|\mathbf{b}\|} \leq \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$$

这是因为,  $\Delta \mathbf{x} = \mathbf{A}^{-1} \Delta \mathbf{b}$ , 从而有  $\|\Delta \mathbf{x}\| \leq \|\mathbf{A}^{-1}\| \cdot \|\Delta \mathbf{b}\|$ , 同理有  $\|\mathbf{b}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$ 。

上式也被称为矩阵的条件数。设  $\mathbf{A}$  为**非奇异矩阵**, 则定义矩阵  $\mathbf{A}$  的条件数  $\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$ 。

矩阵的条件数是**反映线性方程组求解问题的敏感性的条件数的上界**。如果矩阵条件数大, 则问题很**病态**, 此时称该矩阵为**病态矩阵**; 反之则称问题为**良态**。

*Theorem 3.11:* 在任一算子范数下, 有:

$$\text{cond}(\mathbf{A}) = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} / \min_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$$

这是因为,  $\|\mathbf{A}^{-1}\| = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{A}^{-1}\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{x}\|}{\|\mathbf{Ax}\|} = \frac{1}{\min_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}}$ 。这体现出  $\text{cond}(\mathbf{A})$  的几何意义, 也即**对单位圆的扭曲程度**, 同时也说明  $\text{cond}(\mathbf{A}) \geq 1$ 。此外, 定义  $\text{cond}(\text{奇异矩阵}) = +\infty$ 。

*Theorem 3.12:* 矩阵条件数具有如下性质:

1.  $\text{cond}(\mathbf{A}) \geq 1$ ,  $\text{cond}(\mathbf{A}^{-1}) = \text{cond}(\mathbf{A})$ ,  
 $\text{cond}(c\mathbf{A}) = \text{cond}(\mathbf{A})$ ,  $\forall c \neq 0$
2.  $\text{cond}(\mathbf{I}) = 1$
3.  $\mathbf{D}$  为对角阵, 则在  $p$ -范数意义下,  $\text{cond}(\mathbf{D}) = \frac{\max_i |d_{ii}|}{\min_i |d_{ii}|}$ 。
4. 采用2-范数,  $\text{cond}(\mathbf{A}) = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}$
5.  $\mathbf{Q}$  为正交矩阵, 则有  
 $\text{cond}(\mathbf{Q})_2 = 1$   
 $\text{cond}(\mathbf{QA})_2 = \text{cond}(\mathbf{AQ})_2 = \text{cond}(\mathbf{A})_2$

对于正交阵  $\mathbf{Q}$ , 有  $\|\mathbf{Qa}\| = \|\mathbf{a}\|$

$$\text{cond}(\mathbf{QA})_2 = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{QA}\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \text{cond}(\mathbf{A})_2$$

## 3.3矩阵的LU分解

**高斯消去法:** 用初等变换将  $\mathbf{A}$  变为单位阵, 用于算逆矩阵。

*Theorem 3.14:* 对方程  $\mathbf{Ax} = \mathbf{b}$ , 其中  $\mathbf{A} \in \mathbb{R}^{n \times n}$ , 若执行高斯消去过程中的主元  $a_{kk}^{(k)} \neq 0$ ,  $(k = 1, 2, \dots, n-1) \iff$  系数矩阵  $\mathbf{A}$  存在**唯一的LU分解**。

**唯一性的证明:** 假设  $\mathbf{A} = \mathbf{L}_1 \mathbf{U}_1 = \mathbf{L}_2 \mathbf{U}_2$ , 其中  $\mathbf{L}_1, \mathbf{L}_2$  为单位下三角阵 (非奇异)。若  $\mathbf{A}$  非奇异, 则  $\mathbf{U}_1$  也非奇异, 从而有  $\mathbf{L}_1 \mathbf{L}_2^{-1} = \mathbf{U}_2 \mathbf{U}_1^{-1} = \mathbf{I} \implies \mathbf{L}_1 = \mathbf{L}_2, \mathbf{U}_1 = \mathbf{U}_2$ , 矛盾。若  $\mathbf{A}$  奇异, 则  $\mathbf{U}(n, n) = 0$ , 从而有

$$\begin{bmatrix} \mathbf{L}'_1 & \mathbf{0} \\ \alpha_1^T & 1 \end{bmatrix} \begin{bmatrix} \mathbf{U}'_1 & \beta_1 \\ \mathbf{0}^T & 0 \end{bmatrix} = \begin{bmatrix} \mathbf{L}'_2 & \mathbf{0} \\ \alpha_2^T & 1 \end{bmatrix} \begin{bmatrix} \mathbf{U}'_2 & \beta_2 \\ \mathbf{0}^T & 0 \end{bmatrix}$$

进而有  $\mathbf{L}'_1 \mathbf{U}'_1 = \mathbf{L}'_2 \mathbf{U}'_2 \implies \mathbf{L}'_1 = \mathbf{L}'_2, \mathbf{U}'_1 = \mathbf{U}'_2 \implies \mathbf{L}_1 = \mathbf{L}_2, \mathbf{U}_1 = \mathbf{U}_2$ , 矛盾。

**LU分解的用途：**

- 单个方程求解：

$$\mathbf{Ax} = \mathbf{b} \implies \mathbf{x} = (\mathbf{LU})^{-1}\mathbf{b} = \mathbf{U}^{-1}\mathbf{L}^{-1}\mathbf{b}.$$

1. 首先求解单位下三角型方程组  $\mathbf{Ly} = \mathbf{b}$
2. 再求解上三角型方程组  $\mathbf{Ux} = \mathbf{y}$

- 右端项变化的问题：

$\mathbf{Ax}_i = \mathbf{b}_i$ , 只需对每个右端项执行上述两步, 而不需要重复计算LU分解。

### 3.4选主元技术与稳定性

*Theorem 3.15:* 对矩阵  $\mathbf{A} \in \mathbb{R}^{n \times n}$ , 高斯消去过程中**不出现零主元**的充要条件是,  $\mathbf{A}$ 的前  $n-1$  个顺序主子式均不为零, 即  $\det(\mathbf{A}_k) \neq 0, (k = 1, 2, \dots, n-1)$ 。

需要注意的是, 如果高斯消去过程中**不出现零主元**, 则**LU分解存在且唯一**, 但反过来, LU分解存在不能说明高斯消去过程一定没有零主元。例如, 矩阵  $\begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$  就有无穷多个LU分解, 但是高斯消去过程存在零主元。不过, **LU分解存在且唯一与高斯消去过程中不出现零主元等价**。

并且, LU分解的存在性与唯一性与  $\mathbf{A}$  是否奇异无关。**对奇异矩阵  $\mathbf{A}$  也可能完成消去、LU分解**, 例如  $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$  (关键在于LU分解不要求最后一个主元非零), 而非奇异矩阵也不一定有LU分解 (可能需要先进行一些初等行变换)。

通过**选主元技术**, 可以解决主元为零的问题, 同时, 通过将同一列中的最大元素换做主元, 还可以**减小数值误差**, 从而增强算法稳定性。

**部分主元的LU分解：**

$$\mathbf{PA} = \mathbf{LU}$$

其中,  $\mathbf{P} = \mathbf{P}_{n-1}\mathbf{P}_{n-2} \cdots \mathbf{P}_1$  称为**排列阵**, 其为单位阵  $\mathbf{I}$  重排的结果。

数值更稳定的**全选主元**：选取未消去子矩阵中的最大元素, 通过**行、列**交换到主元位置。

$$\mathbf{PAQ} = \mathbf{LU}$$

**算法的稳定性：**

高斯消去法主要受**舍入误差**的影响。通过**向后误差分析**, 我们可以得到其误差的一个上界。设方程  $\mathbf{Ax} = \mathbf{b}$  的数值解为  $\hat{\mathbf{x}}$ , 且  $(\mathbf{A} + \Delta\mathbf{A})\hat{\mathbf{x}} = \mathbf{b}$ , 有

$$\frac{\|\Delta\mathbf{A}\|_\infty}{\|\mathbf{A}\|_\infty} \lesssim n\rho\epsilon_{mach}$$

其中,  $\rho$  为增长因子, 表示  $\mathbf{A}^{(k)}$  (第  $k$  步高斯消去法后得到的矩阵) 与  $\mathbf{A}$  最大元素之比。对于部分选主元方法, 有  $\rho \leq 2^{n-1}$ , 但实际往往远小于这个上界; 对于不选主元的方法,  $\rho$  可能任意大。

## 3.5 对称正定矩阵的Cholesky分解

正定矩阵：所有顺序主子式的行列式均为正；半正定矩阵：所有顺序主子式的行列式均非负

对于对称矩阵 $\mathbf{A}$ ，有

$$\mathbf{A} = \mathbf{L}\mathbf{D}\mathbf{U}_0 = \mathbf{A}^T = \mathbf{U}_0^T \mathbf{D} \mathbf{L}^T$$

从而若高斯消去不中断，LU分解唯一，有 $\mathbf{L} = \mathbf{U}_0^T$ 。

对于**对称正定矩阵** $\mathbf{A}$ ，其LU分解一定存在且唯一，故 $\mathbf{A} = \mathbf{L}\mathbf{D}\mathbf{L}^T$ 唯一存在，且 $\mathbf{D} = \mathbf{L}^{-1}\mathbf{A}\mathbf{L}^T$ 也为对称正定矩阵，其对角元均大于零。故有：

$$\mathbf{A} = \mathbf{L}\mathbf{D}^{\frac{1}{2}}\mathbf{D}^{\frac{1}{2}}\mathbf{L}^T = \mathbf{L}_1\mathbf{L}_1^T$$

此称为**Cholesky分解**，由于其分解为一组对称阵的乘积，存储量可以节省一半。

### Cholesky分解算法（平方根法）

与直接LU分解的思想类似。

$$\begin{bmatrix} l_{11} & 0 & \cdots & 0 \\ l_{21} & l_{22} & \ddots & \vdots \\ \vdots & \vdots & \ddots & 0 \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ 0 & l_{22} & \cdots & l_{n2} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & l_{nn} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

考虑对应位置元素相等，有（**原地存L的结果**）

$$a_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} a_{jk}^2} \quad j = 1, 2, \dots, n$$
$$a_{ij} = (a_{ij} - \sum_{k=1}^{j-1} a_{ik}a_{jk})/a_{jj} \quad i = j+1, \dots, n$$

**算法的稳定性：**

考虑**增长因子**

$$\rho = \frac{\max\{|U^T(i, j)|\}}{\max\{|a_{ij}|\}} = \frac{\max\{|l_{ij}l_{jj}|\}}{\max\{|a_{ij}|\}} \leq \frac{\max\{l_{ij}^2\}}{\max\{a_{ii}\}} \leq 1$$

注：由上平方根算法，可知 $\mathbf{A}$ 的对角元是 $\mathbf{L}$ 一行元素的平方和。

## 3.6 带状矩阵解法与稀疏矩阵简介

### 3.6.1 带状矩阵

矩阵 $\mathbf{A} = (a_{ij})_{n \times n}$ ，若 $\forall i, j, |i - j| > \beta$ 时都有 $a_{ij} = 0$ ，且 $\exists k, a_{k, k-\beta} \neq 0$ 或 $a_{k, k+\beta} \neq 0$ ，则称 $\mathbf{A}$ 为**半带宽为 $\beta$ 的带状矩阵**。对于带状矩阵，其LU分解中， $\mathbf{L}$ 、 $\mathbf{U}$ 矩阵的**非零元**依然分布在**原始带宽范围内**。

注意，对于带状矩阵的LU分解，其 $\mathbf{A}^{-1}$ 、 $\mathbf{L}^{-1}$ 、 $\mathbf{U}^{-1}$ 均稠密，因此应避免再计算逆矩阵。

**按行对角占优矩阵：** $|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|, i = 1, 2, \dots, n$ ，且至少有一个大于号成立。（若均为严格大于，则称为**严格对角占优矩阵**）。

**Theorem 3.20：**按列严格对角占优阵，列主元LU分解不需要交换行。

### 3.6.2稀疏矩阵

- **三元组** (COO) : 值、行下表、列下标
- **压缩稀疏行** (CSR) : 值、 (按行顺序存储的) 列下标的列表、每行开头在列表中的位置  
CSR是为了解决COO中连续存储的元素有相同的行 (列) 编号的问题
- **压缩稀疏列** (CSC)
- **若干个一维数组**: 针对带状矩阵, 每个数组存储一条带
- **分块压缩稀疏行**: 针对分块矩阵

在进行稀疏矩阵有关的计算时, 不存储零元素, **只需遍历所有非零元**。而对稀疏矩阵做高斯消去时, 填入的元素可能会造成稀疏矩阵存储结构的变化。